作业7

要求

在MapReduce上实现K-Means算法并在小数据集上测试。可以使用附件的数据集,也可以随机生成若干散点的二维数据(x, y)。设置不同的K值和迭代次数,可视化聚类结果。 提交要求同作业5,附上可视化截图。

实现思路

我直接使用了实例代码来运行,用原来的代码创建maven项目KMeansExample。由于原来的代码不是用maven管理的,而且是基于Hadoop1.2编写的程序,所以有一些地方需要进行小小的修改。比如每个java文件前面都要加上对应的包名称,Job对象的创建需要调用getInstance静态方法,而不能直接new Job。我尝试研读了整个算法的代码,下面简要描述一下示例代码的思路。

主程序: KMeansDriver.main()

KMeansDriver.main()方法是整个算法的主程序,它从命令行接收指定的参数k(需要聚成的类数),iterationNum(迭代次数),inputpath,outputpath。依次调用三个主要的过程:

generateInitialCluster(): 随机产生k个cluster center

clusterCenterJob(): 迭代更新cluster center KMeansClusterJod(): 最终计算各个点所属的类

```
public static void main(String[] args) throws IOException, InterruptedException,
ClassNotFoundException{
   System.out.println("start");
   Configuration conf = new Configuration();
   //命令行传入参数k,iterationNum,输入输出路径
   int k = Integer.parseInt(args[0]);
   int iterationNum = Integer.parseInt(args[1]);
   String sourcePath = args[2];
   String outputPath = args[3];
   KMeansDriver driver = new KMeansDriver(k, iterationNum, sourcePath,
outputPath, conf);
   //随机生成k个cluster center
   driver.generateInitialCluster();
   System.out.println("initial cluster finished");
   //调用迭代的MapReduce过程,不断更新cluster center
   driver.clusterCenterJob();
   //迭代完成后, 计算每个点所属的类
   driver.KMeansClusterJod();
}
```

更新簇中心: KMeans

在clusterCenterJob()方法中,通过循环提交KMeans job来实现cluster center的迭代更新。

```
public void clusterCenterJob() throws IOException, InterruptedException,
ClassNotFoundException{
   for(int i = 0;i < iterationNum; i++){
      Job clusterCenterJob = Job.getInstance(this.conf);
      ...
   }
}</pre>
```

KMeansMapper

KMeansMapper在setup方法中,读取上一次迭代/初始随机生成的cluster文件,生成k个Cluster类。

```
while((line = in.readLine()) != null){
    System.out.println("read a line:" + line);
    Cluster cluster = new Cluster(line);
    cluster.setNumOfPoints(0);
    kClusters.add(cluster);
}
```

在mapper方法中,对于每个样本点,计算样本点离哪个cluster center最近,然后构造包含该点的cluster,类别就是所属的类。

```
id = getNearest(instance);
if(id == -1)
    throw new InterruptedException("id == -1");
else{
    Cluster cluster = new Cluster(id, instance);
    cluster.setNumOfPoints(1);
    System.out.println("cluster that i emit is:" + cluster.toString());
    context.write(new IntWritable(id), cluster);
}
```

KMeansCombiner和KMeansReducer

KMeansCombiner对同类的cluster对象进行合并,将cluster center加权产生新的cluster center。
KMeansReducer和Combiner做的事情相同,也是将同类cluster对象合并,最后输出的就是更新后的cluster,和对应的cluster center坐标。

```
int numOfPoints = 0;
for(Cluster cluster : value){
    numOfPoints += cluster.getNumOfPoints();
    instance =
instance.add(cluster.getCenter().multiply(cluster.getNumOfPoints()));
}
Cluster cluster = new Cluster(key.get(),instance.divide(numOfPoints));
```

```
cluster.setNumOfPoints(numOfPoints);
context.write(NullWritable.get(), cluster);
```

计算每个点所属的类: KMeansCluster

由于迭代过程生成的输出都是cluster center的信息,所以最后判断每个点属于哪一个类还需要做一次 MapReduce。KMeansCluster中,只需要设计mapper方法,对每一个点计算离它最近的cluster center,对应的 cluster id就是它的类别,reducer不需要做任何事,最后直接将点的坐标和cluster id输出即可。

```
id = getNearest(instance);
if(id == -1)
    throw new InterruptedException("id == -1");
else{
    context.write(value, new IntWritable(id));
}
```

运行和输出

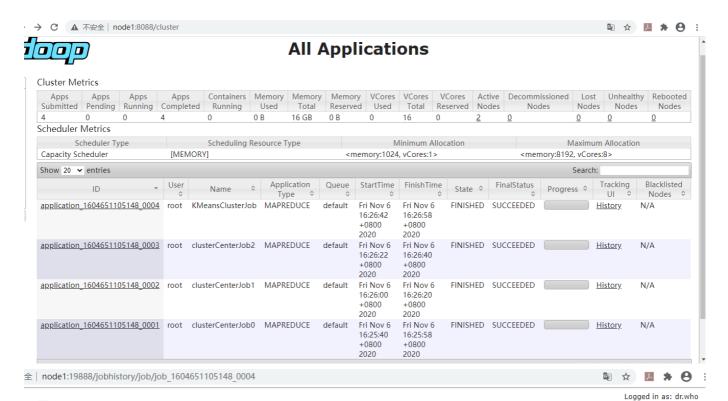
运行需要指定的参数有: k,iterationNum,输入路径,输出路径。格式为:

hadoop jar [包名称] [KMeansDriver类名称] k iterationNum inputpath outputpath

我的作业中,如果聚成3类,迭代次数为3,则命令为:

hadoop jar KMeansExample-1.0-SNAPSHOT.jar com.hw7.KMeansDriver 3 3 KMeans/input KMeans/output 最终聚类的结果在output\result1\clusteredInstances中。

运行截图



doop

MapReduce Job job_1604651105148_0004

Job Name: KMeansClusterJob

User Name: root
Queue: default
State: SUCCEEDED

Uberized: true
Submitted: Fri Nov 06 16:26:42 CST 2020
Finished: Fri Nov 06 16:26:58 CST 2020
Finished: Elapsed: Zsec
Diagnostics:
Average Map Time

KMeansClusterJob

Indiana ClusterJob

In

ApplicationMaster				
Attempt Number	Start Time	Node	Logs	
1	Fri Nov 06 16:26:49 CST 2020	node1:8042	<u>logs</u>	

Task Type	Total		Complete
<u>Map</u>	1	1	
<u>Reduce</u>	0	0	
Attempt Type	Failed	Killed	Successful
Maps	<u>0</u>	0	1
Reduces	<u>0</u>	<u>0</u>	<u>0</u>



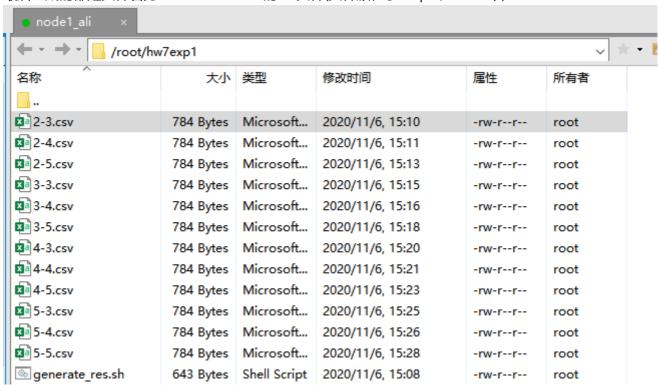
设置不同的k和迭代次数并可视化

为了更加方便地设置不同k和iterationNum来运行。我直接写了一个脚本: generate_res.sh, 脚本自动迭代不同的参数, 然后将输出从hdfs中提取出来, 保存为csv文件。

```
#开始迭代,从聚2个类开始
for((k=2;k<=$k_max;k++))
```

```
do
    for((n=3;n<=$iternum_max;n++))
    do
        hadoop jar KMeansExample-1.0-SNAPSHOT.jar com.hw7.KMeansDriver $k $n
KMeans/input KMeans/output
        hdfs dfs -get KMeans/output/clusteredInstances/part-m-00000
        mv part-m-00000 $k"-"$n".csv"
        hdfs dfs -rm -r KMeans/output
        done
done</pre>
```

最后生成的都是文件名为"k-iterationNum"的csv文件(文件放在了output/result2中)



每个csv文件中,第一列和第二列是样本的两个维度,第三列是对应的类,用matlab画出分类的效果图即可。 下面是一些例子:

